






1. **Identificar a frase completa:**
"O rato roeu a roupa do Rei de Roma".
2. **Enumerar as palavras da frase para encontrar a quinta:**
 - 1ª palavra: O
 - 2ª palavra: rato
 - 3ª palavra: roeu
 - 4ª palavra: a
 - 5ª palavra: roupa
3. **Analisar a quinta palavra ("roupa"):**
Vamos isolar os caracteres da palavra "roupa":
 - 1ª letra: R
 - 2ª letra: O
 - 3ª letra: U
 - 4ª letra: P
 - 5ª letra: A
4. **Conclusão:**

A divisão de tokens impacta as respostas da IA ao definir como ela "enxerga" e processa o texto. Como o modelo não lê palavras inteiras, mas sim pedaços (tokens), ele pode falhar em tarefas de precisão absoluta, como soletrar ou fazer cálculos exatos, já que lida com blocos estatísticos e não com letras individuais. Além disso, o limite de tokens determina a memória de curto prazo da IA; quando uma conversa fica muito longa e atinge o teto da "janela de contexto", os tokens iniciais são descartados para dar lugar aos novos, fazendo com que a IA esqueça instruções anteriores. Por fim, a geração sequencial, onde cada próximo token é previsto por probabilidade, afeta diretamente a velocidade e a lógica da resposta, pois quanto mais fragmentada for a divisão, mais processamento é exigido e maior o risco de o modelo gerar termos incoerentes ao tentar encaixar o próximo "bloco" matemático na sequência.